

第10章 T/TCP实现:TCP函数

10.1 概述

本章包括了 T/TCP作过修改的各个 TCP函数。也就是说 , tcp_output(前一章)、tcp_input ,和tcp_usrreq(后两章)以外的所有函数。本章定义了两个新的函数 ,tcp_rtlookup和tcp_gettaocache ,用于在TAO缓存中查找记录项。

tcp_close函数修改以后,当使用T/TCP的连接关闭时,可以在路由表中记录往返时间估计值(平滑的平均值和平均偏差估计)。常规协议只在连接上传送了至少16个满数据报文段后才记录。然而,T/TCP通常只发送少量数据,但与同一对等端之间的这些不同连接的估计值应该保留下来。

T/TCP中对 MSS选项的处理也有所改变。有一部分改变是为了在 Net/3中清理过载的 tcp_mss函数,这样就把它分成了一个计算 MSS以便发送的函数(tcp_mssend)和另一个处理接收到的MSS选项的函数(tcp_mssrcvd)。T/TCP同时也将从对等端收到的最新 MSS值保存到TAO缓存记录项中。在接收到服务器的 SYN和最新的MSS之前,如果要随SYN发送数据,T/TCP就用这个记录来初始化发送MSS。

Net/3中的tcp_dooptions函数修改以后能够识别三个新的 T/TCP选项: CC、CCnew和 CCecho。

10.2 tcp_newtcpcb函数

用PRU_ATTACH请求创建新的插口时要调用该函数。图 10-1中的五行代码用来代替卷 2第 667页的第177~178行。

```
180 tp->t_maxseg = tp->t_maxopd = tcp_mssdflt; tcp_subr.c

181 if (tcp_do_rfc1323)

182 tp->t_flags = (TF_REQ_SCALE | TF_REQ_TSTMP);

183 if (tcp_do_rfc1644)

184 tp->t_flags |= TF_REQ_CC; tcp_subr.c
```

图10-1 tcp_newtcpcb 函数:T/TCP所做的修改

180 在前面图8-3有关的介绍中提到过,t_maxopd是每个报文段中可以发送的 TCP选项加上数据的最大字节数。它和t_maxseg的默认值均为512(tcp_mssdflt)。由于这两个值相等,表明报文段中不能再有 TCP选项。在后面的图 10-13和图 10-14中,如果时间戳选项或者 CC选项(或者两者同时)需要在报文段中发送,就要减小t_maxseg的值。

183-184 如果全局变量tcp_do_rfcl644非零(它的默认值为1),且设置了TF_REQ_CC标志,这将使tcp_output伴随SYN发出CC或CCnew选项(图9-6)。

- tcp_subr.c



10.3 tcp_rtlookup函数

451

452 }

return (rt);

tcp_mss(卷2第717~718页)执行的第一项操作是读取为该连接所缓存的路由 (存储在

```
– route.h
46 struct route {
47
       struct rtentry *ro_rt;
                                   /* pointer to struct with information */
48
       struct sockaddr ro_dst;
                                    /* destination of this route */
49 };
                                图10-2 route 结构
                                                                           tcp_subr.c
432 struct rtentry *
433 tcp_rtlookup(inp)
434 struct inpcb *inp;
435 {
436
        struct route *ro;
437
       struct rtentry *rt;
438
       ro = &inp->inp_route;
439
       rt = ro->ro_rt;
440
        if (rt == NULL) {
441
            /* No route yet, so try to acquire one */
442
            if (inp->inp_faddr.s_addr != INADDR_ANY) {
443
                ro->ro_dst.sa_family = AF_INET;
444
                ro->ro_dst.sa_len = sizeof(ro->ro_dst);
445
                ((struct sockaddr_in *) &ro->ro_dst)->sin_addr =
446
                    inp->inp_faddr;
447
                rtalloc(ro);
448
                rt = ro->ro_rt;
449
            }
450
```

图10-3 tcp_rtlookup 函数

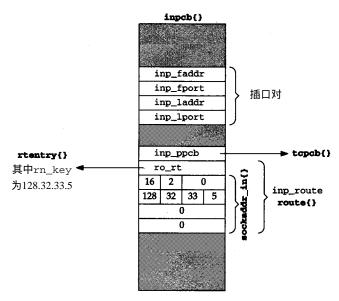


图10-4 在Internet PCB中缓存的路由全貌



Internet PCB的inp_route字段中),如果该路由还没有缓存过,则调用 rtalloc查找路由。现在这项操作安排在另一个独立的函数 tcp_rtlookup中实现,我们将在图 10-3中介绍。这样做是因为连接的路由表记录项中包括有 TAO信息,T/TCP需要更经常地执行这一项操作。438-452 如果这个连接的路由还没有在缓存中记录, rtalloc就计算出路由。但仅仅当 PCB中的外部地址非 0时才能计算路由。在调用 rtalloc之前,要先填写 route结构中的 sockaddr_in结构。

图10-2给出了route结构,其中的一个结构在每个Internet PCB中都有。

图10-4给出了这个结构的全貌,图中假定外部地址为128.32.33.5。

10.4 tcp_gettaocache函数

一个给定主机的 TAO信息保存在该主机的路由表记录项中,确切地说,是在 rt_metrics结构的rmx_filler字段中(见6.5节)。图10-5所示的函数tcp_gettaocache返回指向该主机TAO缓存的指针。

```
tcp_subr.c
458 struct rmxp_tao *
459 tcp_gettaocache(inp)
460 struct inpcb *inp;
461 {
        struct rtentry *rt = tcp_rtlookup(inp);
462
        /* Make sure this is a host route and is up. */
463
464
        if (rt == NULL |
            (rt->rt_flags & (RTF_UP | RTF_HOST)) != (RTF_UP | RTF_HOST))
465
            return (NULL);
466
        return (rmx_taop(rt->rt_rmx));
467
468 }
                                                                          - tcp_subr.c
```

图10-5 tcp_gettaocache 函数

460-468 tcp_rtlookup返回的指针指向外部主机的rtentry结构。如果查找成功,并且RTF_UP和RTF_HOST标志均打开了,则宏rmx_taop(见图6-3)返回的指针指向rmxp_tao结构。

10.5 重传超时间隔的计算

Net/3的TCP要测量数据报文段往返时间、跟踪平滑的 RTT估计器(*srtt*)和平滑的平均偏差估计器(*rttvar*),并据此计算重传超时间隔(RTO)。平均偏差是标准差的良好逼近,比较容易计算,因为与标准差不一样,平均偏差不需要做平方根运算。文献 [Jacobson 1988]给出了RTT测量的其他细节,并导出以下的计算公式:

```
delta = data - srtt
srtt \quad srtt + g \times delta
rttvar \quad rttvar + h(|delta| - rttvar)
RTO = srtt + 4 \times rttvar
```

其中,delta是刚刚得到的往返时间测量值 (data)与当前的平滑的 RTT估计器 (srtt)之差;g是应用于RTT估计器的增益,等于 1/8;h是应用于平均偏差估计器的增益,等于 1/4。在RTO计算



中的两个增益和乘数 4特意取为 2的乘幂,因此可以通过移位操作来代替乘除运算。卷 2的第25章给出了如何用定点整数来保存这些值的有关细节。

在常规的TCP连接中,在计算 srtt和rttvar 这两个估计器时,通常要对多个 RTT取样,对于图1-9中的给定最小TCP连接来说,至少要有两个样本。而且,在一定条件下, Net/3将对相同主机之间的多个连接运用这两个估计器。这是 tcp_close函数实现的,在一个连接关闭时,如果有关对等端的路由表记录项不是默认路由,并且至少得到了 16个RTT样值。估计的结果存储在路由表记录项中rt_metrics结构的rmx_rtt和rmx_rttvar字段中。新连接建立时,tcp_mssrcvd(见10.8节)从路由表记录项中取出这两个值作为 srtt和rttvar这两个估计器的初始值。

T/TCP中出现的问题是,一个最小连接只有一个 RTT测量值,而且少于16个样值是很正常的,因此在两个对等端之间相继建立拆除的 T/TCP连接对上述测量和估计一点贡献也没有。这就意味着在T/TCP中,第一个报文段发出去时根本就不知道 RTO的取值应该是多少。卷 2的 25.8节讨论了tcp newtcpcb执行初始化时是怎样确定第一个 RTO应该是6秒的。

让tcp_close在即使只收集到少于 16个样值也存储对 T/TCP连接的平滑估计结果并不难 (在10.6节中我们会看到为此所做的修改),但问题是:如何将新估计值与以前的估计值进行归并?不幸的是,这仍然还是一个正在研究的问题 [Paxson 1995a]。

为了理解各种不同的可能性,请考虑图 10-6中的情况。从作者的一台主机上通过 Internet 向另一台主机上的回显服务器发送 100个400字节长的UDP数据报(在一个工作日的下午,通常是Internet上最为拥挤的时候)。93个数据报有回显返回(还有7个不知在Internet的哪些地方丢失了),在图 10-6中给出了前 91个数据报。样值是在 30分钟的时间内采集到的,前后数据报之间的时间间隔是在 0~30秒之间均匀分布的随机数。实际的 RTT是在客户主机上运行 Tcpdump得到的。黑点就是测量得到的 RTT。另外的三条实线(从上至下依次是 RTO、srtt和rttvar)是运用本

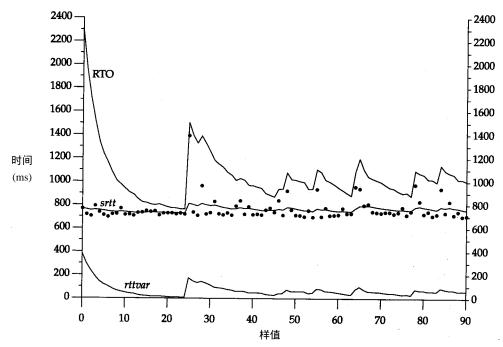


图10-6 RTT测量和对应的RTO、srtt和rttvar



节开头的公式从测得的 RTT计算出来的。计算是用浮点算术完成的,而不是 Net/3中实际所用的定点整数方法。图上所示的 RTO就是从相应的数据点计算出来的值。也就是说,第一个数据点(大约2200 ms)的RTO是从第一个数据点计算得来的,将用作下一个报文段发送时的 RTO。

尽管所测得的RTT值平均都在800 ms以下(作者的客户系统是通过拨号线上的 PPP连接到 Internet上的,穿越整个国家才能到达服务器),第26个样值的RTT几乎达到1400 ms,此后有少量的一些点在1000 ms左右。[Jacobson 1994]指出,"只要是有竞争的连接共享一条路由,瞬间RTT波动达到2倍最小值是完全正常的(它们仅仅表示另外一个连接的开始或丢失后重新开始),因此,RTO小于2×RTT从来就不会是合理的"。

当估计器有新值存储到路由表记录项中时,必须做出判断,对应于已经过去的历史,有 多少信息是新的。这样,计算公式就为:

> $savesrtt = g \times savesrtt + (1 - g) \times srtt$ $saverttvar = g \times saverttvar + (1 - g) \times rttvar$

这是一个低通滤波器,其中 g是取值在 $0\sim1$ 之间的过滤增益常量, savesrtt和 saverttvar是存储在路由表记录项中的数值。当 Net/3用这些公式更新路由表记录时 (当一个连接关闭,并假定得到了16个样值),它采用的增益是 0.5:存储在路由表中的值有一半是路由表中的旧值,另有一半是当前估计的值。 Bob Braden的 T/TCP代码中取增益为 0.75。

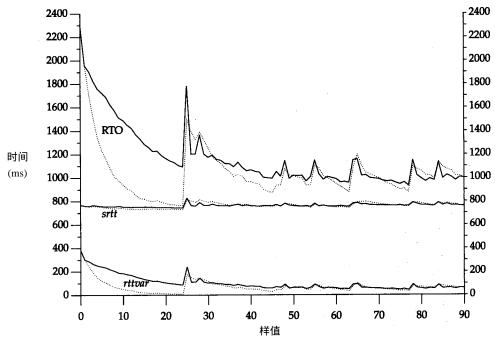


图10-7 TCP平滑与T/TCP平滑的比较

图10-7给出了从图10-6中的数据用常规TCP计算方法算出的结果与用滤波器增益 0.75平滑的计算结果之间的比较。图中的三条虚线就是图10-6中的三个变量(RTO在最上方, srtt在中间, rttvar在底部)。三条实线则是假定每一个数据点都是一个独立 T/TCP连接(每一个连接有一个RTT测量值)所对应的变量,并且采用滤波增益 0.75进行了平滑。要知道有这样的差别:虚线对应的是一个TCP连接在30分钟内的91个RTT样本;而实线对应的则是在同样的 30分钟内91



个独立的T/TCP连接,每个连接有一次RTT测量。实线同时还是91个连接的所有相继两个估计值归并后记录到两个路由度量值中的。

代表srtt的实线和虚线差别不大,但是代表rttvar的实线和虚线之间就有明显的差别。rttvar的实线(T/TCP情况)取值通常大于虚线(单个TCP连接),使T/TCP的重传超时间隔可以取更大的值。

还有其他因素也在影响 T/TCP中的RTT测量。从客户端来看,所测得的 RTT通常包括服务器的处理时间或者服务器的延迟 ACK定时值,因为服务器的应答通常会延迟到这些事件发生后才给出。在 Net/3中,延迟 ACK的定时器值是每 200ms到时一次,而 RTT测量的时间单位为500 ms,因此应答时延不会是一个大的因素。而且 T/TCP报文段的处理常常会在 TCP输入处理中遭遇慢通道(例如,报文段常常不被用于首部预测),会加大测得的 RTT值(然而快通道与慢通道的差别相对于 200 ms的延迟 ACK定时器值来说很可能是可以忽略的)。最后,如果存储在路由表中的值"过时"了(就是说,其最后一次更新是在一个小时以前),在当前事务完成以后,或许应该用当前的测量值直接替换路由表中的值,而不是用新的测量值与已有的测量值归并。

如RFC 1644中所指出的,需要对 TCP中的动态特性作更多的研究,特别是 T/TCP,以及 RTT估计。

10.6 tcp close函数

tcp_close的唯一改变是要为 T/TCP事务记录 RTT估计值,即使还没有凑足 16个样值。 我们在前一节中已经叙述了这样做的原因。图 10-8给出了代码。

```
tcp_subr.c
252
        if (SEQ_LT(tp->iss + so->so_snd.sb_hiwat * 16, tp->snd_max) &&
253
             (rt = inp->inp_route.ro_rt) &&
254
           ((struct sockaddr_in *) rt_key(rt))->sin_addr.s_addr != INADDR_ANY) {
                                 /* pp. 895*896 of Volume 2
304
        } else if (tp->cc_recv != 0 &&
305
                    (rt = inp->inp_route.ro_rt) &&
306
           ((struct sockaddr_in *) rt_key(rt))->sin_addr.s_addr != INADDR_ANY) {
307
            /*
308
              * For transactions we need to keep track of srtt and rttvar
             * even if we don't have 'enough' data for above.
309
310
             */
311
            u_long i;
312
            if ((rt->rt_rmx.rmx_locks & RTV_RTT) == 0) {
313
                i = tp->t_srtt *
314
                     (RTM_RTTUNIT / (PR_SLOWHZ * TCP_RTT_SCALE));
                if (rt->rt_rmx.rmx_rtt && i)
315
316
317
                      * Filter this update to 3/4 the old plus
318
                      * 1/4 the new values, converting scale.
319
                     */
320
                    rt->rt_rmx.rmx_rtt =
321
                         (3 * rt->rt_rmx.rmx_rtt + i) / 4;
322
323
                    rt->rt_rmx.rmx_rtt = i;
324
            }
```

图10-8 tcp_close 函数:为T/TCP事务保存RTT估计值



```
325
            if ((rt->rt_rmx.rmx_locks & RTV_RTTVAR) == 0) {
326
                i = tp->t rttvar *
327
                     (RTM_RTTUNIT / (PR_SLOWHZ * TCP_RTTVAR_SCALE));
328
                if (rt->rt_rmx.rmx_rttvar && i)
329
                    rt->rt_rmx.rmx_rttvar =
330
                         (3 * rt->rt_rmx.rmx_rttvar + i) / 4;
331
                else
332
                    rt->rt_rmx.rmx_rttvar = i;
333
            }
334
                                                                           tcp_subr.c
```

图10-8 (续)

1. 只对T/TCP事务进行更新

304-311 只有在连接中使用了T/TCP(cc_recv非0)、有一路由表记录项存在及不是默认路由时才更新路由表记录项中的度量值。而且,只有当两个 RTT估计值没有加锁(RTV_RTT和RTV_RTTVAR位)时才更新。

2. 更新RTT

312-324 t_srtt是以500 ms x 8为时间单位保存的,rmx_rtt则以 μ s为单位保存。这样,t_srtt就要乘1 000 000(RTM_RTTUNIT)除2(时间单位/秒)再乘8。如果rmx_rtt已经有值,新记录值就是旧值的四分之三加上新值的四分之一。这就是取滤波增益为 0.75,我们在前一节已讨论过。否则,直接将新值保存到 rmx_rtt中。

3. 更新平均偏差

325-334 对平均偏差估计值应用同样的算法。它也以 ms为单位保存,需要将 t_r ttvar中的单位时间 \times 4。

10.7 tcp_msssend函数

在Net/3中,有一个函数 tcp_mss(卷2的27.5节),在处理MSS选项时tcp_input要调用它,在需要发送 MSS选项时tcp_output也要调用它。在 T/TCP中,这个函数改名为tcp_mssrcvd,在执行隐式连接建立时,收到 SYN后,tcp_input要调用它(在后面的图10-18中,确定是否需要在 SYN中包含MSS选项),以及PRU_SEND和PRU_SEND_EOF请求要调用它(见图12-4)。有一个新的函数 tcp_msssend,如图10-9所示,只有当发出了 MSS选项时,才会被tcp_output调用。

```
tcp_input.c
1911 int
1912 tcp_msssend(tp)
1913 struct tcpcb *tp;
1914 {
         struct rtentry *rt;
1915
1916
        extern int tcp_mssdflt;
        rt = tcp_rtlookup(tp->t_inpcb);
1917
1918
         if (rt == NULL)
1919
            return (tcp_mssdflt);
1920
          * If there's an mtu associated with the route, use it,
1921
             图10-9 tcp msssend 函数:返回MSS值,并在MSS选项中发出
```



```
1922  * else use the outgoing interface mtu.
1923  */
1924  if (rt->rt_rmx.rmx_mtu)
1925    return (rt->rt_rmx.rmx_mtu - sizeof(struct tcpiphdr));
1926  return (rt->rt_ifp->if_mtu - sizeof(struct tcpiphdr));
1927 }
```

图10-9 (续)

1. 读取路由表记录项

1917-1919 为每一个对等主机搜索路由表,如果没有找到记录项,则返回默认值 512(tcp mssdflt)。除非对等主机不可达,否则总是可以查找到一个路由表记录项的。

2. 返回MSS

1920-1926 如果路由表有一个关联的MTU(rt_metrics结构中的rmx_mtu字段,系统管理员可以用route程序设置),就返回该值。否则,返回值就取输出接口的MTU减去40(例如,以太网上是1460)。因为路由已经由tcp_rtlookup确定,输出接口也是已知的。

在路由表中存储 MTU度量的另一个来源是利用路由 MTU发现过程(卷1的24.2节), 尽管Net/3中还不支持这种方法。

这个函数不同于通常的BSD做法。如果对等端是非本地主机(由in_localaddr函数决定), 而且rmx mtu度量值为0,则Net/3代码(卷2第719页)中总是将MSS取为512(tcp mssdflt)。

MSS选项的目的是告诉另一端,该选项发送者准备接收多大报文段。 RFC 793 中指出,MSS选项"用于交流发送这个报文段的 TCP的最大可接收报文段"。在一些实现中,这可能受主机能够重装的最大 IP数据报限制。然而在当前的大多数系统中,合理的限制决定于输出接口的MTU,因为如果需要分段并且发生报文段丢失,则 TCP的性能会下降。

下面的注释摘抄于 Bob Braden的T/TCP源码修改:"非常不幸,使用 TCP选项要求对 BSD 作可观的修改,因为它对 MSS的处理是错误的。 BSD总是要发出 MSS选项,并且对非本地网络的主机,这个选项的值是 536。这是对 MSS选项用途的误解,这个选项是要告诉发送者,接收者准备处理什么。这时发送主机要决定用多大的 MSS,既要考虑它接收的 MSS选项,还要考虑到路由情况。当我们有了 MTU发现以后,这个路由很可能有一个大于 536的MTU;这样,BSD就会降低吞吐率。因此,这个程序只确定了应该发送什么样的 MSS选项:本地接口的MTU减去40。"(这段注释中讲到的值536应为512)。

我们在下一节 (图10-12)中会看到,如果对等端是非本地主机 , MSS选项的接收者才把 MSS减到512。

10.8 tcp_mssrcvd函数

在执行隐式连接建立时,收到 SYN以后的tcp_input要调用tcp_mssrcvd, PRU_SEND和PRU_SEND_EOF也都要调用它。该函数与卷2中的tcp_mss函数相似,但是它们之间还是有足够的差别,能够完成我们所需的全部功能。这个函数的主要目标是设置两个变量,一个是t_maxseg(我们在每个报文段中发送的最大数据量),另一个是t_maxopd(在每个报文段中发送的数据加选项的最大长度)。图10-10给出了这个函数的第一部分。



```
tcp_input.c
1755 void
1756 tcp_mssrcvd(tp, offer)
1757 struct tcpcb *tp;
1758 int
            offer;
1759 {
         struct rtentry *rt;
1760
1761
         struct ifnet *ifp;
1762
         int
                 rtt, mss;
         u_long bufsize;
1763
1764
         struct inpcb *inp;
         struct socket *so;
1765
1766
         struct rmxp_tao *taop;
1767
         int
                 origoffer = offer;
1768
         extern int tcp_mssdflt;
        extern int tcp_do_rfc1323;
1769
1770
        extern int tcp_do_rfc1644;
1771
         inp = tp->t_inpcb;
         if ((rt = tcp_rtlookup(inp)) == NULL) {
1772
1773
             tp->t_maxopd = tp->t_maxseg = tcp_mssdflt;
1774
             return;
1775
1776
         ifp = rt->rt_ifp;
1777
         so = inp->inp_socket;
1778
         taop = rmx_taop(rt->rt_rmx);
1779
          * Offer == -1 means we haven't received a SYN yet;
1780
1781
          * use cached value in that case.
          */
1782
         if (offer == -1)
1783
1784
             offer = taop->tao_mssopt;
1785
          * Offer == 0 means that there was no MSS on the SYN segment,
1786
          * or no value in the TAO Cache. We use tcp_mssdflt.
1787
1788
         if (offer == 0)
1789
             offer = tcp_mssdflt;
1790
1791
         else
1792
               * Sanity check: make sure that maxopd will be large
1793
               * enough to allow some data on segments even if all
1794
1795
               * the option space is used (40 bytes). Otherwise
1796
               * funny things may happen in tcp_output.
              */
1797
             offer = max(offer, 64);
1798
         taop->tao_mssopt = offer;
1799
                                                                         — tcp_input.c
```

图10-10 tcp_mssrcvd 函数:第一部分

1. 取对等端的路由及其TAO缓存

1771-1777 tcp_rtlookup查找到达对等端的路由。如果由于某种原因,查找路由失败了, t_maxseg和t_maxopd就同时设置为512(tcp_mssdflt)。

1778-1799 taop指向该对等端的TAO缓存,位于路由表的记录项中。如果因为用户进程调用了sendto(一次隐式连接建立,是PRU_SEND和PRU_SEND_EOF请求的一部分)而调用tcp_mssrcvd,则offer设置为TAO缓存中保存的值。如果TAO中的该值为0,offer就设置为512。TAO缓存中的值被更新。



图10-11给出了该函数的第二部分,与卷2第718页完全相同。

```
-tcp_input.c
1800
1801
          * While we're here, check if there's an initial rtt
1802
          * or rttvar. Convert from the route-table units
1803
          * to scaled multiples of the slow timeout timer.
1804
          */
1805
         if (tp->t_srtt == 0 && (rtt = rt->rt_rmx.rmx_rtt)) {
1806
1807
              * XXX the lock bit for RTT indicates that the value
1808
              * is also a minimum value; this is subject to time.
1809
1810
             if (rt->rt_rmx.rmx_locks & RTV_RTT)
1811
                 tp->t_rttmin = rtt / (RTM_RTTUNIT / PR_SLOWHZ);
1812
             tp->t_srtt = rtt / (RTM_RTTUNIT / (PR_SLOWHZ * TCP_RTT_SCALE)):
1813
             if (rt->rt_rmx.rmx_rttvar)
1814
                 tp->t_rttvar = rt->rt_rmx.rmx_rttvar /
                      (RTM_RTTUNIT / (PR_SLOWHZ * TCP_RTTVAR_SCALE));
1815
1816
             else
1817
                 /* default variation is +- 1 rtt */
1818
                 tp->t_rttvar =
1819
                     tp->t_srtt * TCP_RTTVAR_SCALE / TCP_RTT_SCALE;
1820
             TCPT_RANGESET(tp->t_rxtcur,
1821
                            ((tp->t_srtt >> 2) + tp->t_rttvar) >> 1,
1822
                            tp->t_rttmin, TCPTV_REXMTMAX);
1823
         }
                                                                        – tcp_input.c
```

图10-11 tcp_mssrcvd 函数:用路由表度量值初始化RTT变量

1800-1823 如果还没有该连接的 RTT测量值(t_srtt为0),并且rmx_rtt度量值为非0,这时变量t srtt、t rttvar和t rxtcur就用路由表记录项中保存的度量值初始化。

如果路由表度量值加锁标志中的RTV_RTT位已经设置,则它表明还要用rmx_rtt来初始化这次连接的最小RTT(t_rttmin)。默认情况下,t_rttmin初始化为两个时钟步进,这为系统管理员替换该默认值提供了一个方法。

图10-12给出了tcp_mssrcvd的第三部分,用于设置自动变量mss的值。

```
-tcp input.c
1824
1825
          * If there's an mtu associated with the route, use it.
1826
          */
1827
         if (rt->rt rmx.rmx_mtu)
             mss = rt->rt_rmx.rmx_mtu - sizeof(struct tcpiphdr);
1828
1829
         else {
             mss = ifp->if_mtu - sizeof(struct tcpiphdr);
1830
             if (!in_localaddr(inp->inp_faddr))
1831
                 mss = min(mss, tcp_mssdflt);
1832
1833
1834
         mss = min(mss, offer);
1835
          * t_maxopd contains the maximum length of data AND options
1836
1837
          * in a segment; t_maxseg is the amount of data in a normal
          * segment. We need to store this value (t_maxopd) apart
1838
          * from t_maxseg, because now every segment can contain options
1839
1840
          * therefore we normally have somewhat less data in segments.
          */
1841
         tp->t_maxopd = mss;
1842
                                                                         – tcp_input.c
```

图10-12 tcp_mssrcvd 函数:计算mss 变量的值



1824-1834 如果该路由关联于一个MTU(rmx_mtu度量值),那就用这个值。否则,mss就取输出接口的MTU减去40。另外,如果对等端是在另一个网络,或者也可能在另一个子网(由in_localaddr函数决定)中,这时mss的最大值取为512(tcp_mssdflt)。如果路由表记录项中已经保存有MTU,那就不再进行本地-非本地测试。

2. 设置t maxopd

1835-1842 t_maxopd设置为mss,包括了数据和选项的最大报文段长度。

图10-13给出的是第四部分代码,将mss减去在每一个报文段中都有的选项长度。

```
tcp_input.c
1843
1844
          * Adjust mss to leave space for the usual options.
1845
          * called from the end of tcp_dooptions so we can use the
          * REQ/RCVD flags to see if options will be used.
1846
1847
          */
1848
         /*
1849
          * In case of T/TCP, origoffer == -1 indicates that no segments
1850
          * were received yet (i.e., client has called sendto). In this
1851
          * case we just guess, otherwise we do the same as before T/TCP.
          */
1852
         if ((tp->t_flags & (TF_REQ_TSTMP | TF_NOOPT)) == TF_REQ_TSTMP &&
1853
             (origoffer == -1 ||
1854
1855
              (tp->t_flags & TF_RCVD_TSTMP) == TF_RCVD_TSTMP))
1856
             mss -= TCPOLEN_TSTAMP_APPA;
1857
         if ((tp->t_flags & (TF_REQ_CC | TF_NOOPT)) == TF_REQ_CC &&
1858
             (origoffer == -1 ||
1859
              (tp->t_flags & TF_RCVD_CC) == TF_RCVD_CC))
1860
             mss -= TCPOLEN_CC_APPA;
1861 #if (MCLBYTES & (MCLBYTES - 1)) == 0
1862
       if (mss > MCLBYTES)
1863
            mss &= ~ (MCLBYTES - 1);
1864 #else
        if (mss > MCLBYTES)
1865
            mss = mss / MCLBYTES * MCLBYTES;
1867 #endif
                                                                        -tcp_input.c
```

图10-13 tcp_mssrcvd 函数:根据选项减小mss

3. 如果使用时间戳选项就减小mss

1843-1856 如果下面中的任何一个条件为真,则 mss就减去时间戳选项的长度 (TCPOLEN TSTAMP APPA,即12字节):

- 1) 本地端将使用时间戳选项(TF_REQ_TSTAMP),并且还没有收到另一端发来的 mss选项 (origoffer等于-1);或
- 2) 已经收到另一个端发来的时间戳选项。

在代码的注释中指出,由于tcp_mssrcvd是在tcp_dooptions结束时所有的选项处理完以后调用的(见图10-18),因此第二项测试是成功的。

4. 如果使用CC选项,就减少mss

1857-1860 通过相似的逻辑, mss的值减去8字节(TCPOLEN CC APPA)。

这两个长度名称中出现术语 APPA是因为, RFC 1 323的附录 A中建议在时间戳选项前面置两个空字符 NOP, 以便两个 4字节时间戳值的长度都能取 4字节的整数倍。



同时RFC 1644也有一个附录 A ,它对选项排列没有说什么。无论怎样,在三个 CC选项的任一个前面都置两个 NOP是有一定道理的,如图 9-6所示。

5. 舍入MSS为MCLBYTES的倍数

1861-1867 mss要舍入取整为MCLBYTES的整数倍,即每个mbuf簇的字节数(通常为1024或2048)。

这段代码有一个糟糕的优化企图,即如果 MCLBYTES是2的整数幂,则可以用逻辑操作来代替乘法或除法运算。自从 Net/1开始,它就已经是一条弯路,应该清除掉。

图10-14给出了tcp_mssrcvd代码的最后一部分,用于设置发送缓存和接收缓存的大小。

```
tcp_input.c
1868
         /*
          * If there's a pipesize, change the socket buffer
1869
          * to that size. Make the socket buffers an integral
1870
          * number of mss units; if the mss is larger than
1871
          * the socket buffer, decrease the mss.
1872
          */
1873
         if ((bufsize = rt->rt_rmx.rmx_sendpipe) == 0)
1874
             bufsize = so->so_snd.sb_hiwat;
1875
1876
         if (bufsize < mss)
             mss = bufsize;
1877
1878
         else {
             bufsize = roundup(bufsize, mss);
1879
             if (bufsize > sb_max)
1880
                 bufsize = sb_max;
1881
             (void) sbreserve(&so->so_snd, bufsize);
1882
1883
         }
1884
         tp->t_maxseg = mss;
1885
         if ((bufsize = rt->rt_rmx.rmx_recvpipe) == 0)
1886
             bufsize = so->so_rcv.sb_hiwat;
         if (bufsize > mss) {
1887
             bufsize = roundup(bufsize, mss);
1888
             if (bufsize > sb_max)
1889
                 bufsize = sb_max;
1890
              (void) sbreserve(&so->so_rcv, bufsize);
1891
1892
         }
         /*
1893
          * Don't force slow-start on local network.
1894
          */
1895
         if (!in_localaddr(inp->inp_faddr))
1896
1897
              tp->snd_cwnd = mss;
         if (rt->rt_rmx.rmx_ssthresh) {
1898
1899
               * There's some sort of gateway or interface
1900
               * buffer limit on the path. Use this to set
1901
               * the slow start threshhold, but set the
1902
              * threshold to no less than 2*mss.
1903
              */
1904
              tp->snd_ssthresh = max(2 * mss, rt->rt_rmx.rmx_ssthresh);
1905
1906
         }
1907 }
                                                                         - tcp_input.c
```



6. 改变插口发送缓存的大小

1868-1883 系统管理员可以用route程序设置rmx_sendpipe和rmx_recvpipe这两个度量值。bufsize的值就设置为rmx_sendpipe的值(如果已有定义),或者当前插口发送缓存的高位值。如果bufsize的值小于mss,mss值就减小为取bufsize的值(这是一种强迫MSS取比给定目标的默认值还小的取值方法)。否则,bufsize的值放大,取mss的整数倍(插口缓存的大小总是取报文段长度的整数倍)。上限为sb_max,在Net/3就是262 144。插口缓存的高位值由sbreserve设置。

- 7. 设置t maxseg
- 1884 t_maxseg设置为TCP将发给对等端的最大数据量(不包括常规选项)。
 - 8. 改变插口接收缓存的大小

1885-1892 插口接收缓存的高位值可以用类似的逻辑来设置。例如,对于以太网上的本地连接来说,假定时间戳选项和 CC选项同时都在用,则 t_{maxopd} 将是1460, t_{maxseg} 为1440 (见图2-4)。插口发送缓存和接收缓存都将从它们的默认值 8192 (卷2 的图 16-4)舍入到 8640 (1440×6)。

9. 非本地对等端才有的慢启动

1893-1897 如果对等端不是在本地的网络中 (in_localaddr为假),则把拥塞窗口 (snd_cwnd)设置为1个报文段就开始了慢启动过程。

仅仅当对等端在非本地网中才强迫使用慢启动是 T/TCP修改后的结果。这就使 T/TCP的客户端或服务器端可以向本地对等端发送多个报文段,又不需要慢启动所要 求的额外RTT等待时间(见3.6节)。在Net/3中,总是执行慢启动过程(卷2第721页)。

10. 设置慢启动门限

1898-1906 如果慢启动门限度量值(rmx_ssthresh)非0, snd_ssthresh就设置取该值。 我们在图3-1和图3-3中可以看到MSS和TAO缓存与接收缓存大小之间的交叉影响。在图 3-1

中,客户端执行了一次隐式连接建立,PRU_SEND_EOF请求调用tcp_mssrcvd,其中offer为-1,该函数查找到对应服务器的tao_mssopt值为0(因为客户端刚刚重启)。取MSS为默认值512,因为只使用了CC选项(在第2章的例子中,时间戳无效),减去8字节后变为504。注意,8192舍入为504的整数倍后为8568,这是客户端SYN所通告的窗口。然而,当服务器调用tcp_mssrcvd时,它已经接收到客户端的SYN,其中给定MSS为1460。这个值减去8字节(选项长度)后为1452,8192舍入到1452的整数倍后为8172。这是服务器的SYN中通告的窗口。当客户端处理完服务器的SYN后(图中第三段),客户端再次调用tcp_mssrcvd,这一次offer为1460。这就将客户端的t_maxopd增大至1460,客户端的t_maxseg则增大至1452,客户端的接收缓存因舍入而增至8172。这就是客户端在对服务器的SYN作出ACK时通告的窗口。

在图3-3中,当客户端执行了隐式连接建立时,tao_mssopt值为1460——最近一次从对等端收到的值。客户端通告的窗口为8712,1452的整数倍且大于8192。

10.9 tcp_dooptions函数

在Net/1和Net/2版中,tcp_dooptions只能识别NOP、EOL和MSS选项,并且函数有3个参数。在Net/3中增加了对窗口宽度和时间戳选项的支持后,参数的数量也增加到7个(卷2第



745~746页),其中有3个就是为了时间戳选项而加的。现在又需要支持 CC、CCnew和CCecho选项,参数的数量不是增加反而减少到了5个,因为采用了另一种技术来返回选项是否存在以及它们各自的取值信息。

图10-15给出了tcpopt结构。其中的一个结构是在 tcp_input(唯一可以调用tcp_dooptions的函数)中分配的,并且将指向该结构的指针传给tcp_dooptions,该函数填写结构的内容。在处理接收到的报文段时,tcp_input要用到存储在该结构中的值。

```
- tcp_var.h
138 struct tcpopt {
                                    /* TOF_xxx flags */
139
      u_long to_flag;
                                    /* timestamp value */
       u_long to_tsval;
                                    /* timestamp echo reply */
141
        u_long to_tsecr;
                                    /* CC or CCnew value */
142
        tcp_cc to_cc;
                                    /* CCecho value */
        tcp_cc to_ccecho;
143
144 };
                                                                         – tcp_var.h
```

图10-15 topopt 结构,由top_dooptions 填写数据

图10-16给出了to flag字段可以组合出的4个值。

to_flag	说明
TOF_CC	CC选项存在
TOF_CCNEW	CCnew选项存在
TOF_CCECHO	CCecho选项存在
TOF_TS	时间戳选项存在

图10-16 to flag 的取值

图10-17给出了这个函数的参数说明。前 4个参数与Net/3中的相同,但第 5个参数替换了Net/3版本中的最后3个参数。

图10-17 tcp_dooptions 函数:参数

因为处理EOL、NOP、MSS、窗口宽度和时间戳选项的代码与卷 2第745~747页的代码几乎相同,所以这里不再重复介绍 (差别主要在于对新参数的处理,我们刚刚讨论过)。图10-18给出了这个函数的最后一部分代码,它们用于 T/TCP处理3个新的选项。

1. 检查长度和是否处理选项

1580-1584 选项长度要验证(所有3个CC选项的长度必须都是6)。处理接收到的CC选项时,我们也必须发送相应选项 (如果内核的 tcp_do_rfcl644标志已经设置,则 tcp_newtcpcb要设置TF_REQ_CC标志),并且TF_NOOPT标志不能设置(最后这个标志不允许TCP 在其SYN中发送任何选项)。



2. 设置相应标志并复制4字节值

1585-1588 设置相应的 to_flag值。四个字节的选项值存储在 tcpopt结构的 to_cc字段中,并且要先转换成主机的字节顺序。

1589-1595 如果这是一个SYN报文段,要为该连接设置 TF_RCVD_CC标志,因为收到了CC选项。

3. CCnew和CCecho选项

1596-1623 CCnew和CCecho选项的处理步骤与CC选项的相似。但因为CCnew和CCecho选项仅在SYN报文段中有效,所以要附加一项检测,检查报文段中是否包含 SYN标志。

尽管TOF_CCNEW标志都有正确设置,但从来不去检查它。这是因为在图 11-6中,如果CC选项不存在,则缓存的 CC值是无效的(即需设置为0)。如果存在CCnew选项,则cc_recv仍然有正确设置(注意,在图 10-18中,CC和CCnew选项都在 to_cc中存储其值),并且当三次握手完成时(图11-14),所缓存的值 tao_cc是从cc_recv中复制过来的。

4. 处理收到的MSS

1625-1626 局部变量mss记录的或者是MSS选项的值(如果选项存在),或者是表示选项不存在的0值。在这两种情况下,tcp_mssrcvd都要设置变量t_maxseg和t_maxopd的值。在tcp_dooptions快结束时要调用该函数,因为如图 10-13所示,tcp_mssrcvd使用了TF RCVD TSTMP和TF RCVD CC标志。

10.10 tcp_reass函数

当服务器收到包含数据的 SYN时,假定TAO测试失败或报文段中不包含 CC选项,那么tcp_input就将数据存入缓存队列,等待三次握手过程的完成。在图 11-6中,协议的状态设置为SYN_RCVD,程序有一个分支trimthenstep6,在标号为dodata的程序行(卷2第790页),宏TCP_REASS发现协议状态不是ESTABLISHED,因此调用tcp_reass将报文段存入该连接的失序报文队列(其中的数据并非真的失序;只是因为它是在三次握手过程完成之前到达的。然而,卷2的图27-19底部的两个统计计数器tcps_rcvoopack和tcps_rcvoobyte的累进是不正确的)。

```
tcp_input.c
1580
             case TCPOPT_CC:
                 if (optlen != TCPOLEN_CC)
1581
                     continue:
1582
                 if ((tp->t_flags & (TF_REQ_CC | TF_NOOPT)) != TF_REQ_CC)
1583
                                     /* we're not sending CC opts */
1584
                     continue:
                 to->to_flag |= TOF_CC;
1585
                 bcopy((char *) cp + 2, (char *) &to->to_cc,
1586
                       sizeof(to->to_cc));
1587
                 NTOHL (to->to_cc);
1588
1589
                  * A CC or CCnew option received in a SYN makes
1590
                  * it OK to send CC in subsequent segments.
1591
                  */
1592
                 if (ti->ti_flags & TH_SYN)
1593
                     tp->t_flags |= TF_RCVD_CC;
1594
                  图10-18 top dooptions 函数:新T/TCP选项的处理
```

```
1595
                 break:
             case TCPOPT_CCNEW:
1596
                 if (optlen != TCPOLEN_CC)
1597
                     continue;
1598
                 if ((tp->t_flags & (TF_REQ_CC | TF_NOOPT)) != TF_REQ_CC)
1599
                                      /* we're not sending CC opts */
1600
                 if (!(ti->ti_flags & TH_SYN))
1601
                     continue;
1602
                 to->to_flag |= TOF_CCNEW;
1603
                 bcopy((char *) cp + 2, (char *) &to->to_cc,
1604
                       sizeof(to->to_cc));
1605
                 NTOHL (to->to_cc);
1606
                 /*
1607
                  * A CC or CCnew option received in a SYN makes
1608
                  * it OK to send CC in subsequent segments.
1609
1610
                 tp->t_flags |= TF_RCVD_CC;
1611
1612
                 break;
1613
             case TCPOPT_CCECHO:
                 if (optlen != TCPOLEN_CC)
1614
                      continue:
1615
                  if (!(ti->ti_flags & TH_SYN))
1616
                      continue;
1617
                  to->to_flag |= TOF_CCECHO;
1618
                  bcopy((char *) cp + 2, (char *) &to->to_ccecho,
1619
                        sizeof(to->to_ccecho));
1620
                  NTOHL (to->to_ccecho);
1621
                  break:
1622
              }
1623
1624
         if (ti->ti_flags & TH_SYN)
1625
                                     /* sets t_maxseg */
1626
              tcp_mssrcvd(tp, mss);
1627 }
                                                                         tcp_input.c
```

图10-18 (续)

当对服务器所发的SYN的ACK(通常是三次握手中的第三个报文段)跚跚来迟时,执行卷2第774页的case TCPS_SYN_RECEIVED语句,使连接进入到ESTABLISHED状态,然后调用rcp_reass函数将队列中的数据交付给进程,该函数第二个参数为 0。但在图11-14中,我们会看到,如果新的报文段中有数据,或者如果设置了 FIN标志,就跳过对tcp_reass函数的调用,因为这两种情况的任何一种都会引起对标号为 dodata的TCP_REASS函数的调用。问题是,如果新的报文段完全与以前的报文段重复,则对 TCP_REASS函数的调用不会强行将队列中的数据交付给进程。

修改tcp_reass函数只需做很小的改变:将卷2第729页的第106行的return改为执行标号为present的分支。

10.11 小结

给定主机的TAO信息保存在路由表的记录项中。函数 tcp_gettaocache读取为某主机缓存的TAO数据,但如果在PCB的路由缓存中尚不存在相应的路由,则调用 tcp_rtlookup来查找主机。



T/TCP修改tcp_close函数,在路由表中为T/TCP连接保存两个估计值 srtt和rttvar,即使连接中只传送了不到 16个满长度的报文段。这样就使与该主机的下一次 T/TCP连接可以在开始时使用这两个估计值(假设路由表记录项在下一次连接时还没有超时)。

Net/3的函数 tcp_mss在T/TCP中分成了两个函数: tcp_mssrcvd和tcp_msssend。 前者在收到 MSS选项后调用,后者在发出 MSS选项时调用。后者与通常的 BSD做法的不同之处在于,它一般声明其 MSS为输出接口的 MTU减去TCP和IP首部的长度。 BSD系统会向非本地对等主机声明取值为 512的MSS。

Net/3中的 $tcp_dooptions$ 函数在T/TCP中也有改变。函数的若干个参数取消了,用一个结构来代替。这就使函数可以处理新的选项(例如T/TCP新增加的3个选项),而不需增加参数。